

### **Background & Purpose**



Stack Overflow merupakan platform dan komunitas *online* terbesar yang terpercaya di lingkup *developer* di dunia teknologi. Mereka di sana memiliki tujuan yang sama untuk berbagi pengetahuan tentang *programming*, saling membantu menyelesaikan masalah, dan membangun karir.

#### Manual question Tagging issues:

- Membutuhkan waktu yang lebih banyak (Time consumming)
- Dapat menimbulkan tidak konsistennya tag(May lead to unconsistency)

Karena terdapat berbagai topik yang dibahas, dilakukan tagging untuk mengelompokkan pertanyaan-pertanyaan yang ada ke dalam topik-topik tertentu. Dengan adanya tag pada tiap pertanyaan, hal ini akan memudahkan developer untuk mencari topik-topik tertentu.



Memprediksi tags yang erat kaitannya dengan subjek pertanyaan

## "Seberapa penting implementasi project ini untuk stackoverflow?"

#### Benefit:

- pertanyaannya akan lebih cepat sampai dan tepat sasaran
- pertanyaan akan lebih mudah di identifikasi tags-nya
- Mempermudah memberikan notifikasi kepada pengguna yang akan menjawab dan menargetkan yang punya kompetensi dibidangnya
- Dari sisi penanya, cepat mendapatkan jawaban dan dijawab oleh pengguna yang kompeten
- Dari sisi penjawab, stack overflow akan merekomendasikan pertanyaan-pertanyaan yang relate dengan pertanyaan yang sering dijawab atau memang bidangnya

Dengan demikian, keuntungannya ialah stack overflow dapat membantu manambahkan tags secara otomatis, meminimalisasi tags yang keliru, mempercepat distribusi jawaban dan pertanyaan serta berdampak pada pengalaman pengguna disana

## Overview Project



# Dataset & Library

#### Dataset:

Python Question from Stack Overflow. Full text of Stack Overflow Q&A about the Python programming language

### Library:

**NLTK (Natural Language Toolkit)** 

### **Pre-Processing**

- 1. Merge The Datasets into a Single Dataset
- 2. Filter Dataset Based on 'Score' column and Most Frequently used Tags
- 3. Clean The Data
- 4. Lemmatization
- 5. TF-IDF Vectorization

### **Method Used**

**K-Nearest Neighbors** 






### Datasets Overview

- Questions
- Answers
- Tags





[ ]	answers.head()						
		Id	OwnerUserId	CreationDate	ParentId	Score	Body
	0	497	50.0	2008-08-02T16:56:53Z	469	4	open up a terminal (Applications->Utilit
	1	518	153.0	2008-08-02T17:42:28Z	469	2	I haven't been able to find anything that d
	2	536	161.0	2008-08-02T18:49:07Z	502	9	You can use ImageMagick's convert utility f
	3	538	156.0	2008-08-02T18:56:56Z	535	23	One possibility is Hudson. It's written in
	4	541	157.0	2008-08-02T19:06:40Z	535	20	We run <a href="http://buildbot.net/trac">B</a>

tags.head()				
	Id	Tag		
0	469	python		
1	469	osx		
2	469	fonts		
3	469	photoshop		
4	502	python		


## Merging

The Datasets

```
# Joining answers grouped by 'Id'
grouped_answers = answers.groupby('Id')['Answer'].apply(lambda answer: ' '.join(answer))
grouped_answers = grouped_answers.to_frame().reset_index()

# Joining tags grouped by 'Id'
grouped_tags = tags.groupby('Id')['Tag'].apply(lambda tag: ' '.join(tag))
grouped_tags = grouped_tags.to_frame().reset_index()

# Merging 'Questions' dataframe with 'Answers' dataframe, then with 'Tags' dataframe
df = questions.merge(grouped_answers, how='left', on='Id')
df = df.merge(grouped_tags, how='left', on='Id')
df.drop(columns=['Id', 'OwnerUserId', 'CreationDate'], inplace=True)
```





## Data Cleaning

- Punctuation Removal
- HTML Tags
- Lemmatization
- Stopwords Removal



```
# Dropping 'answer' column since it can't be imputed (because this column values is neither categorical nor continuous in nature) df.drop(columns=['answer'], inplace=True)
def punctuation_remover(text):
    for punctuation in string.punctuation:
        text = text.replace(punctuation, '')
# Changing the data type of 'title' and 'question' columns to string
df['title'] = df['title'].astype(str)
df['question'] = df['question'].astype(str)
# Removing HTML tags on 'question' column values
df['question'] = df['question'].apply(lambda question: re.sub('<[^<]+?>', '', question))
# Applying 'punctuation_remover' function on 'title' and 'question' columns
df['title'] = df['title'].apply(punctuation_remover)
df['question'] = df['question'].apply(punctuation_remover)
df['title'] = df['title'].str.lower()
df['question'] = df['question'].str.lower()
# Splitting the text into words
df['title'] = df['title'].str.split()
df['question'] = df['question'].str.split()
 lematizer = WordNetLemmatizer()
def word_lemmatizer(text):
    lemma_text = [lematizer.lemmatize(word) for word in text]
        return lemma text
# Applying lemmatizer function to 'title' and 'answer' columns
df['title'] = df['title'].apply(lambda title: word_lemmatizer(title))
df['question'] = df['question'].apply(lambda question: word_lemmatizer(question))
df['title'] = df['title'].apply(lambda title: [word for word in title if word not in stopwords.words('english')])
df['question'] = df['question'].apply(lambda question: [word for word in question if word not in stopwords.words('english')])
```



### TF-IDF

Vectorization




```
TF-IDF equation:
TF = (# of times of specific word in a doc) / (# of words in doc)
IDF = log((# of docs) / (# of docs that contains specific word))
TF-IDF = TF * IDF
vectorizer = TfidfVectorizer()
# Changing the data type of 'title' and 'question' columns to string
df['title'] = df['title'].astype(str)
df['question'] = df['question'].astype(str)
X1 = vectorizer.fit_transform(df['title'].str.lower())
X2 = vectorizer.fit_transform(df['question'].str.lower())
```

## Data Modelling

 Using K-Nearest Neighbors algorithm





#### TF-IDF

doc1: saya suka makan

doc2: dia suka minum

doc3: teman saya yang suka dengan dia suka naik sepeda

doc4: abdi sedang jalan-jalan

TF = Jumlah kata spesifik dalam satu dokumen / Jumlah kata dalam satu dokumen

IDF = LOG(Jumlah dokumen / Jumlah dokumen yang mengandung kata spesifik)

TF-IDF = TF x IDF

Perhitungan Pada doc1

-kata spesifik: "suka"

TF = 1 / 4 = 0.25

IDF = LOG(4/3) = 0.1249

TF-IDF = 0.25 x 0.1249 = 0,031225

Jadi, nilai TF-IDF untuk kata "suka" pada doc1 adalah 0,031225



k-nearest neighbors algorithm

Misalkan kita memiliki matriks TF-IDF dan variabel target sebagai berikut:

	saya	makan	bakso	variabel_target
doc1	0.005	0.123	0.03	jajan
doc2	D	0.05	0.2	masak
doc3	0.112	0.003	D	jajan
doc4	0.012	D	D	???

Eucledian Distance =  $sqrt((q1-p1)^2 + (q2-p2)^2 + ... + (qn-pn)^2)$ 

	saya	makan	bakso	jarak_terhadap_doc4
doc1	0.005	0.123	0.03	0.1267
doc2	D	0.05	0.2	0,2065
doc3	0.112	0.003	D	0,1000

misal: k=2

Artinya, dipilih doc3 dan doc1 sebagai 2 tetangga terdekat dengan doc4. doc3 dilabeli "jajan" dan doc1 dilabeli "jajan".

"jajan" = 2

makan = 0

maka, dapat disimpulkan bahwa doc4 memiliki label "jajan"